

a) **Título:** Cuantificación Probabilística de Abundancias Bacterianas en Metaproteómica Usando Triqler

b) Introducción

La metaproteómica, el estudio a gran escala de proteínas extraídas de microbiomas ambientales, permite investigar directamente las dinámicas funcionales en comunidades microbianas (Kleiner et al., 2017). Dado que las proteínas constituyen una proporción significativa del peso seco celular (por ejemplo, el 55% del peso seco de *Escherichia coli*), son excelentes estimadores de biomasa (BNID104954, <http://bionumbers.hms.harvard.edu/bionumber.aspx?id=104954>). En estudios previos se han utilizado datos metaproteómicos para estimar la biomasa de los miembros de la comunidad. No obstante, los métodos para evaluar la biomasa mediante metaproteómica aún no están completamente desarrollados ni validados, y persisten varios desafíos (Kleiner et al., 2017).

La proteómica *shotgun*, que es el método proteómico más común, identifica proteínas al comparar las secuencias peptídicas que se obtuvieron mediante espectrometría de masas con secuencias proteicas conocidas (Kleiner et al., 2017).

La cuantificación precisa de proteínas se dificulta en la proteómica *shotgun label-free* debido a las múltiples fuentes de error que presenta el método. Los *pipelines* tradicionales buscan controlar estos errores a través de una serie de pasos de filtrado; no obstante, con frecuencia se asume que los resultados filtrados son 100% precisos, ignorando consecuentemente dichas fuentes de error (The and Käll, 2019). Tales simplificaciones pueden comprometer el control de la Tasa de Descubrimientos Falsos (FDR) y llevar a interpretaciones engañosas. Para resolver este problema, el modelo bayesiano Triqler tiene la capacidad de cuantificar y propagar explícitamente múltiples fuentes de error en una medida unificada de abundancia diferencial. Los *workflows* tradicionales suelen realizar estimaciones puntuales excesivamente confiadas y filtrados heurísticos. En contraste, Triqler logra mayor sensibilidad y un control más preciso de la tasa de descubrimientos falsos (FDR) al basarse en distribuciones de probabilidad (The and Käll, 2019).

Además, debe considerarse el potencial sustancial para futuros avances en proteómica cuantitativa que podría lograrse combinando QuantUMS con técnicas de análisis estadístico posteriores como Triqler. Esto posibilitaría la realización de inferencias biológicas teniendo en cuenta todas las incertidumbres, datos faltantes y problemas de normalización en los datos proteómicos crudos (Kistner et al., 2023).

Triqler ha demostrado su capacidad para integrarse con métodos convencionales y superarlos en espectrometría de masas de alta resolución, incluidos los *workflows* de adquisición independiente de datos (DIA) (Truong et al., 2023). Esto lo vuelve una

herramienta fundamental, con un sólido marco probabilístico, que ofrece un potencial para la inferencia cuantitativa en sistemas microbianos complejos.

Para comprender las funciones del ecosistema, las interacciones microbianas y los impactos ambientales sobre la composición microbiana, es necesario medir la cantidad de cepas bacterianas en muestras tan complejas. Los métodos computacionales actuales se centran en inferir abundancias proteicas, pero extender estos métodos para estimar de manera confiable abundancias a nivel de cepa todavía es un desafío.

Finalmente, se espera que la nueva versión validada del método Triqler, denominada BacTriqler, proporcione distribuciones de probabilidad confiables para la abundancia de cepas bacterianas. Dadas las ventajas mencionadas, esto proporcionará información esencial para comprender la estructura y dinámica de la comunidad microbiana.

c) Hipótesis y objetivos

Hipótesis

Cuando la evidencia cuantitativa se asigna a múltiples especies estrechamente relacionadas, asignar esta evidencia a su nivel taxonómico compartido más bajo produce estimaciones de abundancia más completas y confiables que excluirla, y debería preferirse en análisis con resolución a nivel de especie.

Objetivo

El objetivo es desarrollar y analizar un método probabilístico para estimar abundancia de cepas bacterianas desde datos metaproteómicos, tratando de forma explícita el asunto de la evidencia peptídica ambigua entre taxones estrechamente relacionados. Este método combinará técnicas cuantitativas basadas en modelos bayesianos, abarcando principalmente una extensión del marco de Triqler, junto con estrategias de asignación al nivel taxonómico compartido para aumentar la solidez y exhaustividad de las estimaciones.

Este proyecto tiene como objetivo adaptar y ampliar las capacidades de Triqler, un método originalmente diseñado para la cuantificación de proteínas en proteómica, para estimar la abundancia de cepas bacterianas a partir de datos metaproteómicos. Al aprovechar el marco bayesiano de Triqler, que resume las abundancias peptídicas en distribuciones de probabilidad de concentraciones proteicas, buscamos desarrollar un modelo probabilístico robusto que refleje con precisión las distribuciones de abundancia de las cepas bacterianas.

Al completar este proyecto, el estudiante adquirirá experiencia en técnicas avanzadas de bioinformática, modelado probabilístico y análisis estadístico, posicionándose a la vanguardia de la investigación en metaproteómica y ecología microbiana.

Objetivos específicos

- Crear una extensión validada del método Triqler capaz de proporcionar distribuciones probabilísticas confiables para cepas bacterianas a partir de datos metaproteómicos.
- Evaluar exhaustivamente el rendimiento del método comparándolo con enfoques existentes.
- Obtener interpretaciones biológicas significativas a partir de un caso de estudio, contribuyendo a la comprensión de la estructura y dinámica de la comunidad microbiana.

d) Metodología

1. **Revisión bibliográfica:** Realizar una revisión bibliográfica exhaustiva para comprender el panorama actual del análisis metaproteómico y la cuantificación bacteriana. Estudiar los fundamentos teóricos y la aplicación del método Triqler en la proteómica estándar.
2. **Recolección y preprocesamiento de datos:** Obtener conjuntos de datos metaproteómicos públicos que incluyan comunidades microbianas bien caracterizadas. Preprocesar los datos para identificar y cuantificar péptidos, asegurando la compatibilidad con los requisitos de entrada de Triqler.
El conjunto de datos metaproteómico público de Kleiner et al. (2017) (PRIDE archive: PXD006118), que contiene comunidades microbianas ensambladas artificialmente con contribuciones de biomasa de cepas conocidas, se utilizará para probar el modelo. La plataforma QuantUMS se empleará para adquirir el conjunto de datos. Esta comunidad sintética sirve como dato de referencia bien definido, permitiendo una evaluación precisa y una comparación rigurosa del rendimiento de BacTriqler en la estimación de abundancias de cepas.
3. **Adaptación del método:** Adaptar los modelos estadísticos de Triqler para tener en cuenta marcadores peptídicos específicos de cada cepa y péptidos compartidos entre distintas cepas. Incorporar información filogenética y taxonómica para mejorar la capacidad del modelo de resolver diferencias a nivel de cepa.
4. **Modelado probabilístico:** Extender el marco bayesiano para inferir la presencia y abundancia de cepas bacterianas. Validar el enfoque comparándolo con abundancias de cepas conocidas en conjuntos de datos metaproteómicos simulados.

5. **Análisis estadístico y benchmarking:** Desarrollar métricas estadísticas para evaluar la exactitud y precisión de las estimaciones de abundancia de cepas. Comparar el rendimiento del Triqler adaptado frente a métodos existentes de cuantificación bacteriana.
6. **Caso de estudio:** Aplicar el modelo desarrollado a datos metaproteómicos reales para demostrar su utilidad práctica. Interpretar la relevancia biológica de los patrones de distribución de cepas en un contexto ecológico o clínico.

e) Factibilidad

Recursos humanos: El proyecto será co-dirigido por Lukas Käll (KTH Royal Institute of Technology – SciLifeLab, Suecia) y Germán Rosano (IBR-CONICET-UNR, Argentina). Käll, experto en proteómica computacional y autor principal de Triqler, brindará orientación metodológica directa. Rosano, especialista en proteómica y co-director de la Unidad de Espectrometría de Masas (UEM-IBR), supervisará los aspectos bioquímicos y analíticos.

Plan de supervisión: Reuniones periódicas asegurarán que la tesista reciba retroalimentación continua sobre el desarrollo del método, los análisis estadísticos y las interpretaciones biológicas.

Disponibilidad de datos y software: El conjunto de validación (PXD006118) es público y está bien caracterizado. Triqler es un software de código abierto escrito en Python, lo que facilita su extensión y reduce el trabajo de programación inicial. Germán Rosano proporcionará las muestras experimentales para el caso de estudio, garantizando acceso a material biológico exhaustivamente caracterizado para la validación del modelo.

Aspectos logísticos: Durante la tesis, el estudiante trabajará de manera remota conectado al Servidor SciLifeLab (ubicado en Estocolmo, Suecia), con los recursos computacionales necesarios para llevar a cabo la investigación.

f) Cronograma de actividades

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6
Revisión bibliográfica	X					
Recolección y preprocesamiento de datos	X					

Adaptación metodológica	X	X				
Modelado probabilístico		X	X			
Análisis estadístico y benchmarking				X		
Caso de estudio					X	
Escritura de tesis					X	X

Fecha de entrega del pre-final de tesis: Julio 2026

g) Referencias bibliográficas

Albanese, D., & Donati, C. (2017). Strain profiling and epidemiology of bacterial species from metagenomic sequencing. *Nature communications*, 8(1), 2260.

Frederick C. Neidhardt AND H. Edwin Umbarger, Chemical Composition of *Escherichia coli*, chapter 3 in Neidhardt F.C. *Escherichia coli* and *Salmonella*: Cellular and Molecular Biology. 2nd edition. Vol 1. American Society of Microbiology (ASM) Press 1996. p.2 table 1

Kistner, F., Grossmann, J. L., Sinn, L. R., & Demichev, V. (2023). QuantUMS: uncertainty minimisation enables confident quantification in proteomics. *BioRxiv*, 2023-06.

Kleiner, M., Thorson, E., Sharp, C. E., Dong, X., Liu, D., Li, C., & Strous, M. (2017). Assessing species biomass contributions in microbial communities via metaproteomics. *Nature communications*, 8(1), 1558.

Milo, R., Jorgensen, P., Moran, U., Weber, G., & Springer, M. (2010). BioNumbers—the database of key numbers in molecular and cell biology. *Nucleic acids research*, 38(suppl_1), D750-D753.

The, M., & Käll, L. (2019). Integrated identification and quantification error probabilities for shotgun proteomics. *Molecular & Cellular Proteomics*, 18(3), 561-570.

Truong, P., The, M., & Käll, L. (2023). Triqler for protein summarization of data from data-independent acquisition mass spectrometry. *Journal of Proteome Research*, 22(4), 1359–1366. <https://doi.org/10.1021/acs.jproteome.2c00607>



Firma de la Tesista

Buenos Aires,
10 de noviembre de 2025

Lugar y Fecha



Firma del director

Stockholm, 2025-11-26

Lugar y Fecha



Firma del Co-director

Rosario, 20 de noviembre de 2025

Lugar y Fecha



Firma del tutor

Buenos Aires, 25/11/25

Lugar y Fecha